

Exploração, descrição e visualização de dados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/FARMA0048>

FARMA0048 - Bioestatística

Programa de Pós-Graduação em Ciências Farmacêuticas (PPGCF)

O papel da análise exploratória em um artigo científico

Por que explorar os dados?

- O objetivo da **análise exploratória** é entender os dados que estamos analisando.
- Isso nos ajuda a entender sobre qual população as inferências de uma pesquisa serão válidas.
- A análise exploratória permite identificar:
 - padrões
 - distribuições
 - diferenças
 - associações
 - valores extremos
 - inconsistências
- Ela ajuda a transformar um banco de dados em **evidência compreensível**.

Exemplo

- Um estudo avaliou a concentração plasmática de um fármaco em 120 pacientes.
- Antes de comparar os tratamentos, precisamos saber:
 - Como as concentrações estão distribuídas?
 - Existem valores extremos?
 - A distribuição é aproximadamente simétrica?
 - Há diferenças aparentes entre os grupos?
 - Existem dados faltantes?
- **Explorar é entender antes de concluir.**

O que é análise exploratória de dados?

- É o conjunto de procedimentos utilizados para **investigar, resumir e visualizar os dados**, buscando identificar estruturas e padrões relevantes.
- Inclui:
 - inspeção dos dados;
 - estatísticas descritivas;
 - tabelas;
 - gráficos;
 - identificação de padrões;
 - identificação de valores discrepantes;
 - avaliação da distribuição das variáveis;
 - investigação inicial de associações.
- **Objetivo principal:** Descobrir como os dados se comportam antes de decidir como analisá-los.

Explorar não é testar

- Na exploração, perguntamos: “O que está acontecendo nos meus dados?”
- No teste de hipótese, perguntamos: “Os dados fornecem evidência suficiente para uma determinada hipótese?”
- **Exemplo:** Estudo com 3 tratamentos para hipertensão.

Exploração:

- Visualizar a pressão arterial em cada grupo;
 - Calcular média, mediana e dispersão;
 - Identificar valores extremos.
- **Primeiro:** entender os dados. **Depois:** testar hipóteses.

Inferência:

- Testar se há evidência de diferença entre os tratamentos.

Quatro etapas diferentes

Etapa	Pergunta principal	Exemplo
Explorar	O que há nos dados?	Existem valores extremos?
Descrever	Como resumir os dados?	Mediana = 12,4 mg/L
Testar hipóteses	Há evidência de uma diferença/associação?	Os tratamentos diferem?
Modelar	Como explicar ou prever um desfecho?	Quais fatores estão associados à resposta?

- Essas etapas são relacionadas, mas não são sinônimas.

Exploração

- Busca compreender a estrutura dos dados sem partir imediatamente para uma conclusão inferencial. Algumas perguntas típicas são:
 - Como os dados estão distribuídos?
 - Há assimetria?
 - Existem valores extremos?
 - Existem grupos distintos?
 - Há associação entre variáveis?
 - Existem padrões inesperados?
- **Exemplo:** Concentração plasmática.

2,1 2,4 2,7 3,0 3,2 3,4 3,8 15,7 *mg/L*

- Antes de realizar qualquer teste precisamos verificar se o valor 15,7 é um erro ou uma observação real (Exploração).

Descrição

- Resume quantitativamente aquilo que foi observado.

Variáveis categóricas

- Frequência absoluta;
- Frequência relativa;
- Proporção.

Variáveis quantitativas

- Média;
 - Mediana;
 - Desvio-padrão;
 - Intervalo interquartil;
 - Quantis.
-
- **Exemplo:** Em 120 pacientes, 72 são mulheres (60%), com idade $54,2 \pm 11,3$ anos e concentração plasmática de 8,7 (6,1–12,4) mg/L.

Testar hipóteses

- Utiliza uma amostra para produzir conclusões sobre uma população ou avaliar hipóteses científicas.
- Aqui temos inferência estatística e não análise exploratória.
- **Exemplo:** A concentração plasmática média difere entre dois tratamentos?
 - Hipóteses:
 - H_0 : não há diferença entre os tratamentos.
 - H_1 : há diferença entre os tratamentos.
- O teste estatístico produz evidências para avaliar essas hipóteses.
- **Importante:** Um teste estatístico não substitui a exploração dos dados.

Modelagem estatística

- Busca representar matematicamente a relação entre variáveis.
- **Exemplo:** Quais fatores estão associados à concentração plasmática do fármaco?

Possíveis variáveis:


- dose;
- idade;
- peso;
- função renal;
- sexo;
- interação medicamentosa.

Um modelo pode permitir:

- estimar associações;
- controlar variáveis de confusão;
- quantificar efeitos;
- realizar previsões.

$$\text{Concentração} = \beta_0 + \beta_1(\text{dose}) + \beta_2(\text{idade}) + \beta_3(\text{função renal}) + \varepsilon$$

As quatro etapas de análise de dados



- **Explorar:** Como os dados se comportam?
- **Descrever:** Como posso resumir esse comportamento?
- **Testar:** Há evidência estatística para a hipótese?
- **Modelar:** Como as variáveis se relacionam e quanto cada uma contribui?

Uma boa análise exploratória precisa responder perguntas

- Uma boa análise exploratória deve permitir responder:
 - Quem foi estudado?
 - O que foi medido?
 - Como cada variável se distribui?
 - Há dados faltantes ou inconsistentes?
 - Existem valores extremos?
 - Há diferenças aparentes entre grupos?
 - Existem associações entre variáveis?
 - Há padrões ao longo do tempo?

Para cada variável, pergunte:

1. O que é? (Qual é o tipo variável?)
 2. Como se distribui? (Quais valores são frequentes? Há assimetria?)
 3. Há problemas? (Observações faltantes, valores impossíveis ou extremos?)
 4. Há relações? (A variável parece associada a outras?)
 5. O que isso implica? (Como devo descrever, visualizar e analisar essa variável?)
- **Exemplo:** Concentração plasmática (mg/L)
 - quantitativa contínua
 - assimétrica à direita
 - 3 valores extremos
 - maior concentração aparente no grupo tratado com dose alta
 - Isso já produz decisões analíticas.

A exploração orienta a estatística descritiva

- A escolha da estatística descritiva **não deve ser automática.**
- A distribuição dos dados orienta como resumir os dados.
- Exemplo:
 - Distribuição aproximadamente simétrica: média $\pm$ desvio-padrão
 - Idade (distribuição aproximadamente simétrica): 52,4 $\pm$ 11,2 anos
 - Distribuição assimétrica: mediana (intervalo interquartil – IQQ)
 - Concentração plasmática (distribuição assimétrica): 8,4 (5,7–13,8) mg/L

Não existe “uma estatística certa” para toda variável

- A mesma variável pode exigir diferentes formas de resumo dependendo dos dados.
- **Exemplo:** Considere a concentração plasmática de um fármaco.
 - média = 18,7 mg/L
 - mediana = 10,2 mg/L
 - A diferença entre as duas medidas sugere que **alguns valores elevados estão deslocando a média para cima.**
 - Precisamos investigar:
 - histograma;
 - boxplot;
 - valores extremos;
 - assimetria.

A exploração orienta o gráfico

Situação	Gráfico
Categórica	Barras
Quantitativa	Histograma
Quantitativa	Boxplot
Quantitativa × quantitativa	Dispersão
Quantitativa × categórica	Boxplot / pontos
Evolução temporal	Linhas
Duas categóricas	Barras / tabela

O gráfico pode revelar o que a média esconde

Considere dois grupos:

- Grupo A: 10, 11, 12, 13, 14
- Grupo B: 2, 3, 4, 21, 30
- As médias podem ser semelhantes, mas as distribuições são completamente diferentes.
- A visualização permite perceber:
 - dispersão;
 - assimetria;
 - agrupamentos;
 - valores extremos;
 - diferenças entre grupos.
- Nunca analise isoladamente uma medida-resumo!

A exploração orienta o teste estatístico

Antes de comparar grupos, precisamos saber:

- qual é o desfecho;
- quantos grupos existem;
- se os dados são independentes;
- como a variável se distribui;
- se existem valores extremos importantes;
- qual é a escala de medida.

A exploração orienta o teste estatístico

Exemplo: Concentração plasmática em dois grupos.

Exploração:

- variável quantitativa;
- grupos independentes;
- distribuição aproximadamente simétrica.
 1. uma possibilidade é o **teste t para grupos independentes**.
 2. Se a distribuição for fortemente assimétrica, pode ser necessário considerar outra abordagem, como Mann-Whitney.
- **O teste é consequência da estrutura dos dados.**

Exemplo – Estudo farmacêutico

Pergunta: Um novo fármaco reduz a pressão arterial?

- Banco de dados:
- $n = 180$ pacientes;
- grupo controle e tratamento;
- pressão arterial;
- idade;
- sexo;
- pressão basal;
- pressão após 12 semanas.

Exemplo – Estudo farmacêutico

- Exploração:
 - Há dados faltantes?
 - A pressão arterial apresenta distribuição aproximadamente simétrica?
 - Existem valores extremos?
 - Os grupos apresentam características diferentes?
 - Idade ou pressão basal parecem relacionadas ao desfecho?
- As respostas orientam:
 - estatística descritiva
 - gráficos
 - teste ou modelo
 - apresentação dos resultados

Qualidade dos dados

Dados

- Uma análise estatística é tão confiável quanto os dados que a alimentam.
- Antes de calcular médias, utilizar testes ou modelos, precisamos verificar:
 - estrutura do banco;
 - valores possíveis;
 - codificação;
 - unidades;
 - duplicações;
 - dados faltantes;
 - valores extremos.
- **Erro no banco → análise incorreta → resultado incorreto → conclusão incorreta.**

Exemplo de banco de dados

id	grupo	idade	sexo	oleosidade_baseline	oleosidade_8sem
001	Controle	34	F	72	69
002	Controle	29	F	68	70
003	Controle	41	M	75	73
004	Tratamento	32	F	71	52
005	Tratamento	37	F	69	48
006	Tratamento	45	M	77	54

- Cada linha representa um participante. Cada coluna representa uma variável.

Inspeção inicial do banco de dados

Antes de analisar, precisamos conhecer a estrutura do banco:

Antes da análise, verifique:

- número de participantes e variáveis;
- tipo e unidade de cada variável;
- valores mínimos e máximos;
- dados faltantes;
- duplicações;
- códigos e categorias.

O que fazer: documente a estrutura do banco e faça uma checagem sistemática antes da análise.

Valores impossíveis ou biologicamente absurdos

Exemplos:

- idade = 250 anos;
- peso = -20 kg;
- pH = 25;
- concentração = -5 mg/L.

O que fazer: verificar a fonte original; corrigir apenas se houver evidência de erro e, se não for possível confirmar, tratar como dado faltante.

Erros de codificação

Exemplo: sexo (1 = feminino, 2 = masculino)

- Dados: 1 2 1 7 2
- O 7 pode ser erro, categoria desconhecida ou outra codificação.

O que fazer: consultar o dicionário do banco/protocolo antes de recodificar.

Unidades de medida inconsistentes

- Uma mesma variável pode estar em escalas diferentes.

Exemplo: Concentração na mesma base de dados medida em

- mg/L
- $\mu\text{g/mL}$
- ng/mL

O que fazer: converter todas as observações para uma única unidade antes da análise.

Dados duplicados

Exemplo:

ID	Grupo	Idade
101	Controle	35
102	Tratamento	41
101	Controle	35

- O participante 101 aparece duas vezes.

O que fazer: confirmar se é duplicação ou medida repetida; remover apenas duplicações indevidas.

Dados faltantes – *missing data*

- Um dado faltante ocorre quando uma informação esperada não foi registrada.
- Exemplo:

ID	Grupo	Idade	Oleosidade
001	Controle	34	72
002	Controle	29	NA
003	Tratamento	41	58

O que fazer: quantifique a proporção de missing e investigue seu padrão antes de decidir como tratá-los.

Dados faltantes – *missing data*

Quando eliminar ou imputar?

- Se há poucos valores faltantes e ausência aparentemente aleatória, pode ser aceitável fazer **análise por casos completos** (*complete-case analysis*).
 - Nesse caso, removem-se os participantes com dados faltantes.
- Se a quantidade dados faltantes é relevante ou há um padrão relacionado às características dos participantes, deve-se considerar **imputação múltipla**.
 - Pode-se usar métodos de imputação como **MICE** (*Multivariate Imputation by Chained Equations, ou Imputação Múltipla por Equações Encadeadas*).
- **Não imputar** quando o valor representa uma categoria estruturalmente ausente, como “não aplicável”.
- Não existe um percentual universal que determine quando imputar: a decisão depende da quantidade, do padrão e do mecanismo dos dados faltantes.

Valores extremos

Um valor extremo pode ser:

- erro de digitação;
- erro de unidade;
- erro de medição;
- observação biologicamente verdadeira.

Exemplo:

7,1 7,8 8,2 8,5 9,0 31,7

O que fazer: investigar a origem do valor antes de decidir qualquer exclusão.

Descrição de Variáveis Qualitativas

Variável qualitativa: como descrever?

Uma variável qualitativa representa **categorias**, e sua descrição é feita principalmente por:

- Frequência absoluta $\rightarrow n$
- Frequência relativa $\rightarrow$ proporção
- Percentual $\rightarrow \%$

Principais formas de apresentação

Tipo de variável	Descrição	Gráfico
Nominal	$n (\%)$	Barras
Ordinal	$n (\%)$	Barras ordenadas
Binária	$n (\%)$	Barras

Frequência absoluta

- Mostra o número de indivíduos em cada categoria.

- Exemplo:

Reação adversa	n
Sim	18
Não	82

Vantagens

- Simples;
- Fácil interpretação;
- Mantém o tamanho real de cada grupo.

Desvantagens

- Dificulta comparações entre amostras de tamanhos diferentes.

Frequência relativa

- Expressa a participação de cada categoria na amostra.
- Dada por:

$$\frac{\text{frequência da categoria}}{\text{tamanho da amostra}}$$

Exemplo: Se uma categoria tem 18 pacientes e a amostra 100,

$$f_i = \frac{18}{100} = 0,18 \quad \text{ou } 18\%$$

Vantagens

- Permite comparar amostras de tamanhos diferentes.

Desvantagens

- Menos intuitiva que a frequência absoluta para amostras pequenas.

Tabela de frequência

- Dados categóricos podem ser organizados em frequências e percentuais em uma tabela.

Evento adverso	n	%
Náusea	15	15,0
Cefaleia	10	10,0
Rash	5	5,0
Nenhum	70	70,0

Vantagens

- Precisa;
- Compacta;
- Fácil de comparar categorias.

Desvantagens

- Menos visual que um gráfico.

Gráfico de barras

- Para uma variável categórica, uma das melhores visualizações é o **gráfico de barras**.
- Cada categoria da variável é representada por uma barra cuja altura corresponde à frequência.
- Facilita a visualização e comparação das frequências entre categorias.

Vantagens

- Intuitivo;
- Fácil comparação;
- Adequado para muitas categorias.

Desvantagens

- Menos preciso que uma tabela;
- Pode ficar poluído com muitas categorias.

Descrição de variáveis quantitativas

Variável quantitativa: como descrever?

Uma variável quantitativa representa **valores numéricos**.

Para descrevê-la, precisamos avaliar:

- **Tendência central** → onde os dados se concentram
- **Dispersão** → quanto os dados variam
- **Posição** → como os valores se distribuem
- **Forma** → simetria e assimetria

Variável quantitativa: como descrever?

Principais medidas

Aspecto	Medidas
Tendência central	Média, mediana, moda
Posição	Quartis, percentis
Dispersão	Amplitude, variância, DP, IIQ, CV
Forma	Assimetria

- Uma única medida não descreve adequadamente uma distribuição.

Por que uma única medida não é suficiente?

Considere:

- Grupo A: 48, 49, 50, 51, 52
- Grupo B: 20, 30, 50, 70, 80
 - Ambos possuem média igual a 50, mas apresentam distribuições muito diferentes.

O que fazer: apresentar uma medida de tendência central e uma medida de dispersão.

- **Centro sem dispersão fornece uma visão incompleta dos dados.**

Média

- Soma de todos os valores dividida pelo número de observações.
- **Para que serve:** Representar o centro dos dados.
- **Quando usar:** Distribuição dos dados é **simétrica**.
- **Vantagens:**
 - Utiliza todas as observações;
 - Base para diversos métodos estatísticos.
- **Desvantagens:**
 - Sensível a valores extremos;
 - Pode ser pouco representativa em distribuições muito assimétricas.
- **Exemplo:** Dose média = 52,4 mg/dia

Mediana

- Valor que divide os dados ordenados ao meio.
- Representar a posição central da distribuição.
- **Quando usar:** Distribuição dos dados é **assimétrica** ou há muitos valores extremos.
- **Vantagens:**
 - Pouco influenciada por valores extremos;
 - Adequada para distribuições assimétricas.
- **Desvantagens:**
 - Não utiliza diretamente a magnitude de todos os valores.
- **Exemplo:** Concentração mediana = 8,4 mg/L

Moda

- Valor que ocorre com maior frequência.
- **Para que serve:** Identificar o valor mais frequente.
- **Quando usar:** Quando o valor mais frequente possui interesse prático.
- **Vantagens:**
 - Fácil interpretação;
 - Pode ser utilizada quando a média não é adequada.
- **Desvantagens:**
 - Pode não existir;
 - Pode haver mais de uma moda;
 - Pouco informativa para muitas variáveis contínuas.
- **Exemplo:** Dose mais frequente = 50 mg/dia

Quantis

- Valores que dividem os dados ordenados em determinadas proporções.
- **Para que serve:** Descrever a posição dos valores na distribuição.
- **Quando usar:** Quando interessa conhecer a posição relativa das observações.
- **Vantagens:**
 - Úteis para descrever a distribuição;
 - Pouco influenciados por valores extremos.
- **Desvantagens:**
 - Não resumem diretamente toda a variabilidade.
- **Exemplo:** $P_{90} = 18,5 \text{ mg/L}$

Quartis

- Dividem os dados ordenados em quatro partes.
- **Para que serve:** Descrever a posição e a distribuição dos dados.
- **Principais quartis:**
 - $Q1 = P25$;
 - $Q2 = P50 = \text{mediana}$;
 - $Q3 = P75$.
- **Vantagens:**
 - Fáceis de interpretar;
 - Fundamentais para o cálculo do IIQ e do boxplot.
- **Desvantagens:**
 - Não descrevem toda a distribuição.
- **Exemplo:** $Q1 = 5,7 \text{ mg/L}$; $Q3 = 13,8 \text{ mg/L}$

Percentis

- Valor abaixo do qual está determinada proporção dos dados.
- **Para que serve:** Identificar a posição de uma observação dentro da distribuição.
- **Quando usar:** Quando pontos de corte ou posições específicas da distribuição são relevantes.
- **Vantagens:**
 - Fácil interpretação;
 - Úteis para estabelecer referências.
- **Desvantagens:**
 - Percentis extremos podem ser instáveis em amostras pequenas.
- **Exemplo:** $P_{95} = 21,4 \text{ mg/L}$

Amplitude

- Diferença entre o maior e o menor valor.
- **Para que serve:** Medir a extensão total dos dados.
- **Quando usar:** Para uma descrição rápida da variação observada.
- **Vantagens:**
 - Simples;
 - Fácil interpretação.
- **Desvantagens:**
 - Utiliza apenas dois valores;
 - Muito sensível a valores extremos.
- **Exemplo:** Concentração = 5,2–31,7 mg/L

Variância

- Média dos desvios quadráticos em relação à média.
- **Para que serve:** Quantificar a variabilidade dos dados.
- **Quando usar:** Principalmente como base para outros métodos estatísticos.
- **Vantagens:**
 - Fundamental para diversos procedimentos estatísticos;
 - Utiliza todas as observações.
- **Desvantagens:**
 - Unidade fica elevada ao quadrado;
 - Pouco intuitiva para interpretação.
- **Exemplo:** Variância da concentração = $16,4 \text{ (mg/L)}^2$

Desvio-padrão

- Raiz quadrada da variância.
- **Para que serve:** Quantificar a dispersão dos dados na mesma unidade da variável.
- **Quando usar:** Distribuição aproximadamente simétrica.
- **Vantagens:**
 - Fácil interpretação;
 - Amplamente utilizado em artigos científicos.
- **Desvantagens:**
 - Sensível a valores extremos;
 - Menos adequado para distribuições muito assimétricas.
- **Exemplo:** Pressão arterial = 128 ± 14 mmHg

Intervalo interquartil — IIQ

- Diferença entre o terceiro e o primeiro quartil.
- $IIQ = Q_3 - Q_1$
- **Para que serve:** Medir a dispersão dos 50% centrais dos dados.
- **Quando usar:** Distribuições assimétricas ou com valores extremos.
- **Vantagens:**
 - Pouco influenciado por valores extremos;
 - Adequado para distribuições assimétricas.
- **Desvantagens:**
 - Ignora os 50% extremos da distribuição.
- **Exemplo:** $Q_1 = 5,7$; $Q_3 = 13,8 \rightarrow IIQ = 8,1 \text{ mg/L}$

Coeficiente de variação — CV

- Relação entre o desvio-padrão e a média.
- [$CV =$]
- **Para que serve:** Comparar a variabilidade relativa entre medidas.
- **Quando usar:** Quando interessa comparar precisão/variabilidade em diferentes escalas.
- **Vantagens:**
 - Permite comparação relativa;
 - Muito útil em Ciências Farmacêuticas.
- **Desvantagens:**
 - Inadequado quando a média é próxima de zero;
 - Não deve ser utilizado indiscriminadamente.
- **Exemplo:** Método A = CV 4,2%; Método B = CV 11,8%

Média $\pm$ desvio-padrão

- A média sempre deve ser apresentada com o desvio-padrão.
- **Para que serve:** Resumir centro e dispersão.
- **Quando usar:** Distribuição aproximadamente **simétrica**.
- **Vantagens:**
 - Compacta;
 - Amplamente utilizada em artigos científicos.
- **Desvantagens:**
 - Sensível a valores extremos;
 - Pode representar mal distribuições assimétricas.
- **Exemplo:** Idade = $52,4 \pm 11,3$ anos

Mediana (IIQ)

- Apresentação da mediana deve sempre vir acompanhada do intervalo interquartil.
- **Para que serve:** Resumir centro e dispersão de uma distribuição.
- **Quando usar:** Distribuição **assimétrica** ou com valores extremos relevantes.
- **Vantagens:**
 - Robusta a valores extremos;
 - Adequada para distribuições assimétricas.
- **Desvantagens:**
 - Não utiliza diretamente todos os valores;
 - Menos informativa quando a distribuição é aproximadamente simétrica.
- **Exemplo:** Concentração = 8,4 (5,7–13,8) mg/L

Média × mediana

- A relação entre média e mediana ajuda a identificar assimetria.
- **Distribuição aproximadamente simétrica:** $\text{média} \approx \text{mediana}$
- **Distribuição assimétrica:** $\text{média} \neq \text{mediana}$
- **Para que serve:** Orientar a escolha da estatística descritiva.
- **Exemplo:**
 - Média = 18,7 mg/L;
 - Mediana = 10,2 mg/L.
- **Interpretação:** Possível influência de valores elevados.

Relação entre distribuição e estatística descritiva



- Primeiro observe a distribuição; depois escolha como resumir os dados.

Distribuição	Tendência central	Dispersão
Aproximadamente simétrica	Média	DP
Assimétrica	Mediana	IIQ
Valores extremos relevantes	Mediana	IIQ

- **Regra prática:**
 - Simétrica → **média $\pm$ DP**;
 - Assimétrica → **mediana (IIQ)**.
- **Cuidado:** A escolha não deve depender apenas de um teste de normalidade.
- **O que fazer:** Avaliar a distribuição com **histograma, boxplot e medidas descritivas**.

Visualização de variáveis quantitativas (numéricas)


Histograma



Histograma


- **Para que serve:** visualizar a forma da distribuição.
- **Eixo x:** valores ou intervalos da variável.
- **Eixo y:** frequência, frequência relativa ou densidade.
- Cada barra representa um **intervalo de valores**.
- A largura da barra representa a **amplitude do intervalo**.
- A altura representa a quantidade relativa de observações.
- **Observe:** centro, dispersão, assimetria, valores extremos e possíveis múltiplos grupos.
- O formato geral é mais importante que cada barra individual.

Histograma – Distribuição aproximadamente simétrica




- Caudas aproximadamente semelhantes.
- Centro bem definido.
- Média e mediana tendem a ser próximas.
- Nesse caso, $\text{média} \pm \text{DP}$ pode ser uma representação adequada.

Histograma – Assimetria à direita




- Maior concentração de observações em valores baixos.
- Cauda prolongada para valores altos.
- Média tende a ser maior que a mediana.
- Nesse caso deve-se considerar mediana (IIQ) e investigar valores elevados.

Histograma – Assimetria à esquerda




- Maior concentração de observações em valores altos.
- Cauda prolongada para valores baixos.
- Média tende a ser menor que a mediana.
- Nesse caso deve-se considerar mediana (IIQ) e investigar valores elevados.

Histograma – Distribuição multimodal




- Mais de um pico na distribuição.
- Pode indicar subgrupos, diferentes populações, diferentes tratamentos; ou mistura de mecanismos biológicos.
- Deve-se investigar se existem subgrupos antes de resumir todos os participantes com uma única média.

Curva de densidade




- É uma alternativa ao histograma.
- **Para que serve:** facilitar a visualização da forma geral da distribuição.
- **Vantagem:** permite comparar distribuições com diferentes tamanhos amostrais.

Boxplot



Boxplot



Boxplot

- Um boxplot permite comparar: posição central, dispersão, assimetria, valores extremos e distribuição entre grupos.
- **Exemplo:** Concentração plasmática.

Grupo	Mediana	IIQ
Controle	6,8	4,9–8,7
Tratamento	10,4	7,8–14,2


- **O que fazer:** use boxplots lado a lado quando a comparação entre grupos for importante.

Histograma × boxplot

Característica	Histograma	Boxplot
Forma da distribuição	★★★★★	★★
Assimetria	★★★★	★★★
Valores extremos	★★★	★★★★★
Comparação entre grupos	★★	★★★★★
Detalhamento da distribuição	★★★★★	★★

- **Histograma:** melhor para entender a **forma**.
- **Boxplot:** melhor para comparar **grupos e dispersão**.
- Os dois gráficos são **complementares**.

Q-Q plot



Q-Q plot

- Usado avaliar a compatibilidade dos dados com uma distribuição teórica.
- Para avaliar normalidade, compara-se com a **distribuição normal**.
 - Pontos próximos da linha → maior compatibilidade.
 - Curvaturas ou desvios sistemáticos → possíveis diferenças da normalidade.
 - Desvios nas extremidades → podem indicar caudas diferentes ou valores extremos.
- O Q-Q plot é mais informativo que simplesmente olhar média e mediana.

Regra prática para visualizar uma variável quantitativa

1. **Histograma:** observe a forma.
 2. **Boxplot:** observe dispersão e extremos.
 3. **Q-Q plot:** avalie compatibilidade com uma distribuição teórica.
 4. **Estatísticas:** compare média, mediana, DP e IIQ.
 5. **Decisão:** escolha a forma adequada de descrever e analisar os dados.
- **Nenhum gráfico deve ser interpretado isoladamente.**

Fim